Anti Distillation

(Credit by GPT5.2)

一、背景介绍

1.1 大模型蒸馏问题

知识蒸馏（Knowledge Distillation）是当前模型压缩与能力迁移的重要方法。通常流程为：

- 大模型（Teacher）生成高质量输出或logits
- 小模型（Student）拟合Teacher的输出分布
- 通过KL散度最小化：

$$\mathcal{L}_{KD} = KL(p_T || p_S)$$

其中：

- p_T 为Teacher输出分布
- p_S 为Student输出分布

然而，在商业和安全场景下存在问题：

- API输出被收集后可用于训练小模型
- 黑盒蒸馏（Black-box Distillation）可以通过采样数据逼近Teacher
- 模型能力被“复制”

因此产生需求：

> 是否可以在不明显降低输出质量的前提下，使得生成数据对小模型更难学习？

二、核心思想

2.1 Anti-Distillation 目标

我们希望构造一种解码策略，使得：

- 输出仍然语义合理
- 但在概率分布层面**对小模型具有“误导性”**
- 提高蒸馏的KL距离或训练难度

2.2 方法概述：Cross-Model Adversarial Decoding (CMAD)

在解码时：

1. Teacher生成Top-k候选token集合：

   $\mathcal{T}_k = \{t_1, t_2, ..., t_k\}$

2. 对每个候选token，查询Student的概率：

   $p_S(t_i)$

3. 在Teacher高概率集合中，选择：

$$t^* = \arg\min_{t_i \in \mathcal{T}_k} p_S(t_i)$$

即：

> 在Teacher认为“差不多好”的词中，优先选Student最不自信的词。

2.3 改进版本

(1) 加权版本

$$t^* = \arg\max_{t_i} (\log p_T(t_i) - \lambda \log p_S(t_i))$$

其中：

- λ 控制对抗强度

(2) 分布重加权版本

构造新的采样分布：

$$\tilde{p}(t_i) \propto p_T(t_i) \cdot (1 - p_S(t_i))^\alpha$$

优点：

- 可平滑控制扰动
- 不必总选极端token

三、理论动机

3.1 提高蒸馏难度

蒸馏本质是最小化：

$$KL(p_T || p_S)$$

我们的策略使得：

- 采样分布偏向Student低概率区域
- 增大初始KL距离
- 增强学习难度

3.2 直觉解释

小模型难以学习：

- 低频但合法的表达
- 边缘语义替代表达
- 长尾token模式

我们主动偏向这些区域，使其：

- 语义保持
- 统计模式变得“非自然”

四、实验设计

4.1 实验目标

验证以下假设：

1. ✅ 不显著降低大模型输出质量
2. ✅ 提高小模型蒸馏误差
3. ✅ 增加Student收敛时间
4. ✅ 提高蒸馏后模型与Teacher差距

4.2 实验设置

模型选择

角色	模型
Teacher	7B/13B模型
Student	1B/3B模型

数据集

- Instruction tuning 数据
- QA数据 ()
- 推理任务数据 (DeepscaleR)

对比方法

1. 普通Top-k采样
2. Temperature sampling

3. 本文 Anti-Distill 解码

4.3 评估指标

1. 输出质量评估

- Perplexity
- GPT-based evaluation
- 人工评分

2. 蒸馏效果评估

- Student验证集loss
- Student BLEU/ROUGE
- Student与Teacher输出KL距离
- 收敛epoch数

3. 分布分析

- Token entropy变化
- 长尾token比例
- 词频分布偏移

五、预期结果

5.1 输出质量

预期：

- 轻微下降（<5%）
- 语义基本保持

5.2 蒸馏难度

预期：

- Student loss上升 10–25%
- 收敛时间增加 20–40%
- Student生成质量显著下降

5.3 分布现象

预期：

- token多样性增加
- 更长尾
- Student难以学习分布形状

六、可能风险

风险	说明
输出质量显著下降	λ过大
语义偏移	过度对抗
Student适应后仍能收敛	需动态策略

七、可扩展方向

- 动态 λ 调节
- 多Student联合对抗
- 在logits层加入对抗扰动
- 与Watermarking结合

八、进度安排

第一阶段：理论与实现

- ✅ 实现Cross-model decoding框架
- ✅ 实现logits reweight版本
- ✅ 完成小规模实验验证

第二阶段：系统实验

- ✅ 大规模蒸馏实验
- ✅ 不同λ对比
- ✅ 收敛速度分析
- ✅ 分布统计分析

第三阶段：稳定性与泛化

- ✅ 不同任务验证

- ✅ 多Student测试
- ✅ 对比不同规模Teacher

第四阶段：论文整理

- ✅ 理论动机强化
- ✅ 可视化
- ✅ 撰写论文

九、项目贡献点

1. 提出一种推理阶段可部署的anti-distillation机制
2. 不需要修改模型参数
3. 不影响训练
4. 可与watermark技术兼容
5. 可形成商业API保护方案